人工智能复习

作者：哈利波特👑

第一章 绪论

考点

1. 人工智能的定义、概况；
2. 人工智能主要学派及主要观点。

什么是人工智能?

需要先有**信息**、**认识**、**知识**、**智力**、**智能**概念才能定义人工智能。

- 信息：是搭配了**上下文**的**数据**，是经过整理（解释）的数据，例如“今天天气是30摄氏度”，配合上下文（天气和摄氏度）形成了有意义的信息。
- 认识：是用**符号**（例如文字）去整理信息，并且确定它们之间的联系。
- 知识：是被**认识**了的**信息**和信息之间的联系。是经过加工（整理）的信息，例如“水在摄氏度0度以下会结冰”就是一种知识。
- 智力：是**学习**的能力、**解决问题**的能力，强调运用推理来应对问题。
- 智能：定义为**知识集** + **智力**。所以智能就是运用知识来解决问题的能力。

人工智能定义：就是利用机器去模仿人类的智能来解决问题。

人工智能学派及主要观点

符号主义学派（数理逻辑）

- 主要观点：人工智能源于**数理逻辑**。认知基元是符号，以归结原理为基础。
- 应用：IBM提出的`DEEP BLUE`国际象棋和`WATSON`认知系统。

联结主义学派（仿生学）

- 主要观念：人工智能源于**仿生学**。通过神经元连接和相互作用模拟大脑的结构和功能，通过神经网络来实现智能行为。
- 应用：计算机视觉、卷积神经网络、自然语言处理。

行为主义学派（控制论）

- 主要观念：人工智能来源于**控制论**和**反馈机制**。通过模拟生物体在环境中的适应能力和行为来实现智能。
- 应用：强化学习、Google研发的机器狗。

第二章 知识表示和推理

考点

1. 命题逻辑语法、语义；
2. 谓词逻辑语法、语义；
3. 谓词推理规则（等价式、永真蕴含式）以及应用；
4. 命题及谓词逻辑归结推理（子句、子句集、置换与合一、答案提取）。

谓词逻辑

- **项**
    1. **常数（Constant）**：表示特定的对象，例如`a`、`b`、`c`。
    2. **变量（Variable）**：表示可以取不同值的对象，例如`x`、`y`、`z`。
- **谓词**
    1. 谓词符号通常是大写字母，例如P(x)、Q(a,b)。
- **量词**
    1. **全称量词（Universal Quantifier）**：表示对所有的情况都成立，符号为∀，例如∀x P(x)表示“对所有x，P(x)都成立”。
    2. **存在量词（Existential Quantifier）**：表示存在某种情况成立，符号为∃，例如∃x P(x)表示“存在某个x，使得P(x)成立”。

谓词逻辑推理规则

- 假言推理：

  $P \to Q, P \Rightarrow Q$
- 假言否定:

  $P \to Q, \neg Q \Rightarrow \neg P$
- 等等

谓词逻辑应用

- 课件一中有两题例子，可以刷下。

归结推理

需要先了解**反证法**、**子句集**、**归结操作**的概念才能清楚归结推理。

- 反证法

  $P \Rightarrow Q$ 当且仅当 $P \wedge \neg Q \Leftrightarrow False$
- 子句集
    1. 文字：原子公式及其否定。例如：P：正文字，¬P：负文字。
    2. 子句：任何文字的**析取**，当然一个文字自己也是子句。例如：$P \vee Q \vee R$。
    3. 子句集：子句的**合取**集合。例如 $\{P \vee Q, \neg P \vee R, \neg Q\}$这个子句集合表示了一个包含三个子句的集合，其中 $P \vee Q$, $\neg P \vee R$, 和 $\neg Q$ 是各自的子句。在归结推理中，我们可以通过归结操作来处理这些子句，从而推导出新的子句或证明目标。

- 归结操作
    1. 定义：归结操作步骤包括选择两个子句并尝试将它们合并成一个新的子句。合并的过程依赖于通过消解相反的文字来生成新的子句。
    2. 例子：有两个子句{P ∨ Q, ¬Q}，经过归结操作后生成新子句{P}。

归结推理的基本步骤是利用反证法：首先将目标子句的否定加入子句集中，然后通过归结操作处理子句集，直到推导出空子句。根据反证法的原理，这表明目标子句是可证明的。

- 谓词公式转换子句集
    1. 消去蕴涵和等价符号
    2. 内移否定符号¬
    3. 变量标准化（变量换名）
    4. 消去存在量词（`Skolemize`）
    5. 化为前束型
    6. 把母式化成合取范式
    7. 略去全称量词
    8. 把母式用子句集表示
    9. 子句变量标准化（最好每个子句的变量都不一样）
- 合一
    1. 定义：在谓词归结过程中（子句集内）寻找谓词相同但是项不同，把它们不同的项经过置换，使得该谓词项相同，就是合一。
- 置换
    1. 定义：用σ = {v1/t1, v2/t2,..., vn/tn}来表示任一置换。vi /ti 是指表达式中的变量vi以项ti来替换，且不允许vi 用与vi 有关的项ti（但是ti中可以包含其它变量）作置换。
    2. 例子：**{a/x, w/y, f(s)/z}是置换**; **{x/x}, {y/f(x)}不是置换**;、
    3. 置换是同时进行的。
- 复合置换
    1. 过程：θ={t1/x1,...,tn/xn}，λ={u1/y1,...,um/ym},求θ°λ
        1. 构成{t1λ/x1,...,tnλ/xn,u1/y1,...,um/ym};（可想象成先置换t1λ/x1,...,tnλ/xn这一部分再一个一个置换λ）
        2. 如果yj∈(x1,...,xn)，则删除uj/yj;**（即替换的变量前面已经被换过了）**（**要记得是θ先做变换的，只要是θ里面更换的变量，λ都要删除**）
        3. 如果tkλ=xk,　则删除tkλ/xk;**（类似 y / y这种）**
    2. 性质：(θ° λ)° μ=θ° (λ° μ) 成立，θ° λ=λ ° θ 不一定成立。
- 最一般合一项（MGU）算法：

    给定两个原子公式 f 和 g：

    1. 初始化：

        σ={ };S={f,g}

        σ 是当前的**替换集**，初始为空。 S 是包含两个公式 f 和 g 的集合。
    2. 检查 S 是否包含相同的一对公式。如果是，停止并返回 σ 作为 f 和 g 的 MGU。
    3. 否则，找到 S 中不一致的项集 D={e1,e2}。

4. 检查不一致的项：
    - 如果 e1=V 是一个变量，并且 e2 是不包含 V 的项（反之亦然），则更新替换集： σ=σ ° {V=t};S=S ° {V=t}。
5. 否则，停止，表示 f 和 g 不能被合一。1

- 应用归结原理求解问题
    1. 就是把待求解的问题**否定**加上与`A(x)`**析取**转换成子句并加入到子句集合中，运用归结操作求解答案。

第三章 搜索技术

考点

1. 盲目搜索（深度搜索、宽度搜索、迭代加深搜索）；
2. 启发式搜索（最好优先搜索、A*搜索）；
3. 博弈树搜索（极大极小过程、alpha-beta剪枝）。

搜索的形式化定义

1. 状态空间：即整个要搜索的空间。
2. 动作：即在当前这个状态需执行的动作。
3. 初始状态：就是自己目前的状态。
4. 目标状态：目标的状态。
5. 启发式函数：指导搜索的方向。

除此之外，搜索算法还包括**后继函数**、**动作成本**以及如何**选择下一步动作**（这个最重要）等等。

盲目搜索（无信息搜索）

采用**固定**的选择策略来选择下一个状态。

宽度优先搜索

1. 定义：把当前要扩展的状态的后继状态放在边界的**最后**。
2. 性质：宽度优先搜索具有**完备性**和**最优性**。
    - 完备性：宽度优先从短到长从上到下慢慢搜索，最终一定能找到目标状态。
    - 最优性：根据宽度优先搜索定义，短的路径一定会在长的路径前被探索完，所以一定有最优性。
    - 时空复杂度：时空复杂度开销很大，都是O(b^{d+1})，特别是空间复杂度。

深度优先搜索

1. 定义：把当前要扩展的状态的后继状态放在边界的**最前面**。
2. 性质：深度优先搜索不具有**完备性**和**最优性**。
    - 完备性：如果状态空间无限或者存在回路则找不到目标状态；若状态空间有限并且一直进行剪枝的话具有完备性。
    - 时空复杂度：时间复杂度为O(b^m)，空间复杂度**O(bm)**。

迭代加深搜索

其实就是深度优先和宽度优先缝合；具有宽度优先的优势（每个节点都搜索），也具有深度优先的优势（搜索快）

1. 定义：迭代加深搜索从**深度限制为0**开始，逐渐增加深度限制，直到找到目标节点或搜索完整个图。每次搜索都是**深度优先搜索**，但只允许到当前的最大深度限制为止。
2. 性质：具有**完备性**和**最优性。**
    - 完备性：类似宽度优先一样。
    - 最优性：类似宽度优先一样。
    - 时空复杂度：空间复杂度为O(b^{d})（跟宽度优先一样，可是不用提前存储下一层的节点）；时间复杂度为O(bm)（跟深度优先一样）。

启发式搜索

对于一个具体问题，构造专用于该领域的**启发式函数 $h(n)$**, 该函数用于估计从节点n到达目标节点的成本。要求对于所有满足目标条件的节点n，有$h(n)$ = 0。并且使用**评价函数f(n)**来选择下个要到达的状态。**f(n) = g(n) + h(n)**

- g(n)是初始节点到n的实际代价。

贪婪最佳优先搜索

1. 定义：就是利用启发式函数**h(n)** 来对边界上的节点进行排序，然后每次选择**h(n)**最小的节点n去搜索。
2. 评价函数（可以理解成）：**f(n) = h(n)**
3. 性质：没有**完备性**和**最优性。**

A*算法

1. 定义：就是利用评价函数**f(n)** 来对边界上的节点进行排序，然后每次选择**f(n)**最小的节点n去搜索。
2. 评价函数：**f(n) = g(n) + h(n)**
    - 启发式函数**h(n)**可采纳性：假设$h^*(n)$ 是从节点n到目标节点的最优路径的成本，当对于所有节点n，满足$h(n) \le h^*(n)$，h(n)是可采纳的。
        - 为什么叫可采纳，是因为一直低估了最优的代价，可以让A*算法更好的找到最优解。
    - 启发式函数**h(n)**一致性：对于任意节点$n1$和$n2$，若 $h(n1) \le c(n1 \to n2) + h(n2)$ 则$h(n)$具有一致性。
        - 为什么叫一致性，因为保证f值是**非递减**的。

$$
\begin{aligned}
&\text{由于一致性性质：}\\
&h(n) \le c(n, n') + h(n')\\
&\text{可以推导出：}\\
&f(n) \le g(n) + c(n, n') + h(n')\\
&\text{其中 } g(n') = g(n) + c(n, n')\text{，所以：}\\
&f(n') = g(n') + h(n') = g(n) + c(n, n') + h(n')
\end{aligned}
$$

- **证明：一致性可推可采纳性：**
    1. 假设启发式函数 h(n)是一致的。
    2. 假设 h(n) 不是可采纳的。这意味着存在某个节点 n 使得 h(n)>h∗(n)。
    3. 选择一个实际从起始节点 s 到目标节点的最优路径，并设这个路径为 s,n1,n2,...,ng，其中 ng 是目标节点。
    4. 在这条路径上，由于 h 是一致的，我们有：
    $$h(s) \leq c(s, n_1) + h(n_1)$$
    $$h(n_1) \leq c(n_1, n_2) + h(n_2)$$
    $$\vdots$$
    $$h(n_{g-1}) \leq c(n_{g-1}, n_g) + h(n_g)$$
    5. 由于目标节点 ng 的启发值为零（即 h(ng)=0），将这些不等式相加得到：
    $$h(s) \leq c(s, n_1) + c(n_1, n_2) + \ldots + c(n_{g-1}, n_g) + h(n_g)$$
    $$h(s) \leq c(s, n_g)$$
    6. 因为 c(s,ng)c(s, n_g)c(s,ng) 就是从 sss 到 ngn_gng 的最小实际代价 h∗(s)h^*(s)h∗(s)，所以： h(s)≤h∗(s)
    7. 这与假设的 h(s)>h∗(s) 矛盾。因此，假设 h(n) 不是可采纳的前提是错误的。
3. 性质：**可能**具有最优性。
    - 一致性可以推出可采纳性。
    - 如果**h(n)**只具有可采纳性，没有环检测的情况下是有最优性的。有环检测则不是。
    - 如果**h(n)**具有一致性，就算有环检测，也有最优性。

博弈树搜索

Minimax算法

1. 定义：假设对方能总是做出最优的行动，己方总是做出能最小化对方获得的收益的行动，通过最小化对方的收益，可以最大化己方的收益。
2. 使用**深度优先搜索。**（模拟算法很重要）

剪枝

只要计算节点n的一部分子节点就可以确定在`MiniMax`算法中我们不会考虑走到节点n了；如果已经确定节点n不会被考虑，那么也就不用继续计算n的子节点了。如下图：`x`和`y`已经不用被搜索了。

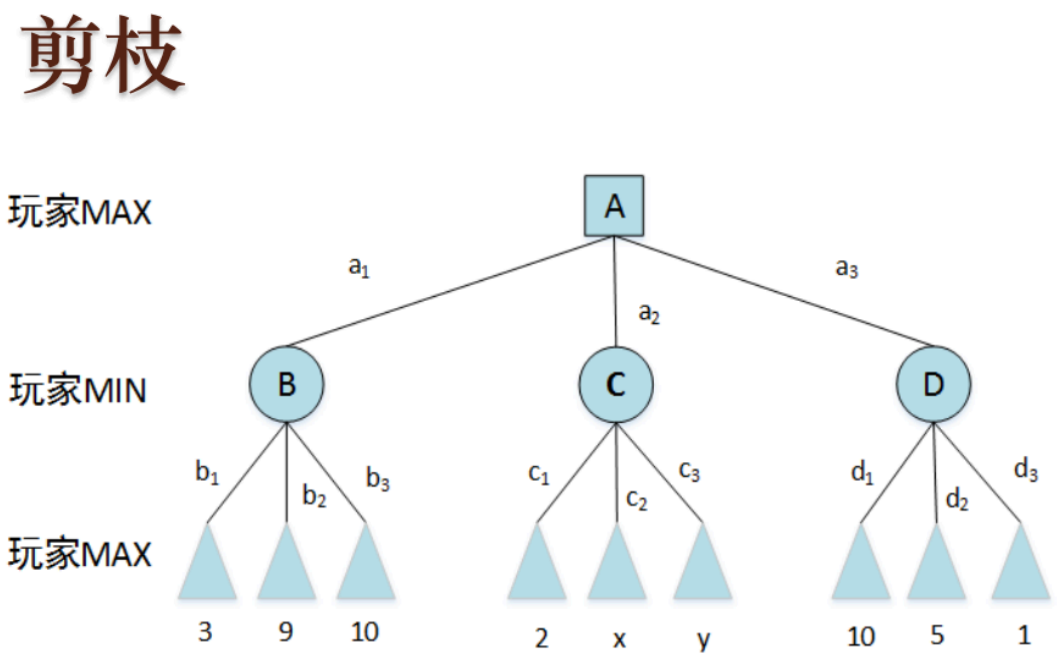

- MAX剪枝：对于Max节点n，如果它的α(子) ≥ β(父)的时候，就可以停止遍历n的子节点了。

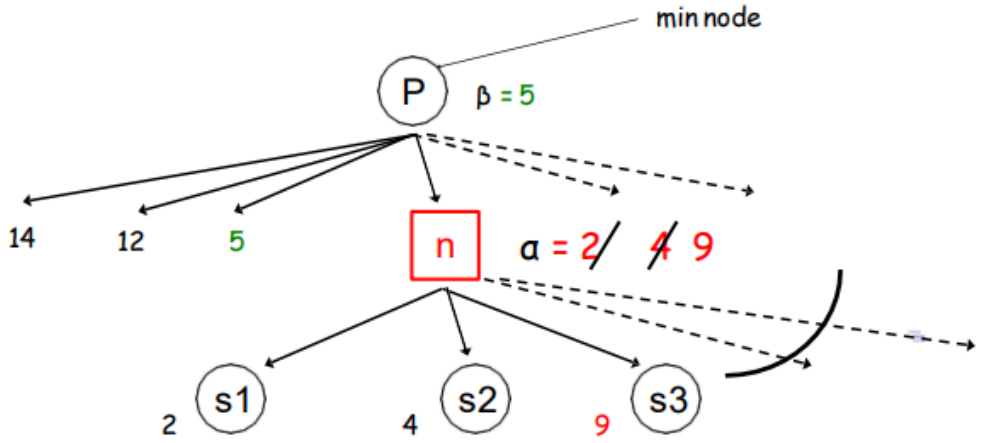

- MIN剪枝：对于Min节点n，如果它的α(父) ≥ β(子)的时候，就可以停止遍历n的子节点了。

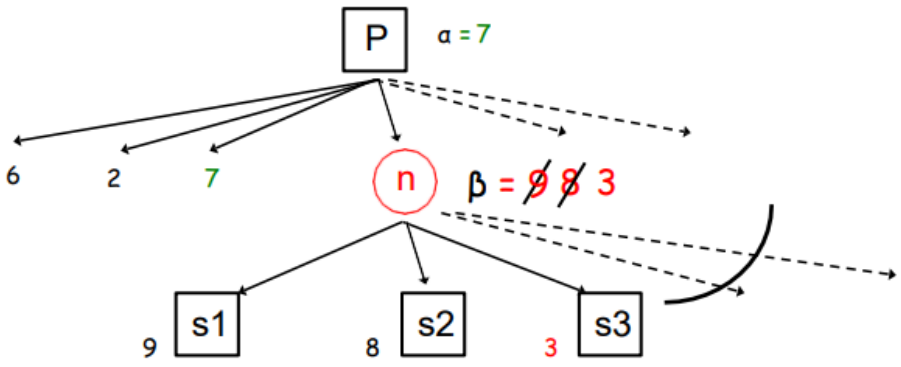

简单来说，对于Min节点n, 如果β值变得 ≤ 某个Max 祖先节点的α值, 那么就可以停止扩展n节点了。Max节点也是一样的。

要记得！是α ≥ β就可以发生剪枝！

第四章 高级搜索

考点

1. 爬山法（基本思想）；
2. 遗传算法（基本操作）（旅行商问题）。

爬山法（基本思想）

- 是一种**贪婪局部搜索算法。** 能很快**朝着解的方向进展。**
- 登高：一直向值增加的方向持续移动，将会在到达一个 “峰顶”时终止，并且在相邻状态中没有比它更高的值。 这个算法保留搜索得路径，因此当前节点的数据结构只需要记录当前状态和它的目标函数值。
- 优点：
    1. 它们只用很少的内存。（因为没有保留搜索得路径）
    2. 它们通常能在很大状态空间中找到合理的解。
- 可以把爬山法想象成一种地形图，既有“位置”（用状态定义），又有“高度”（用启发式函数定义）。

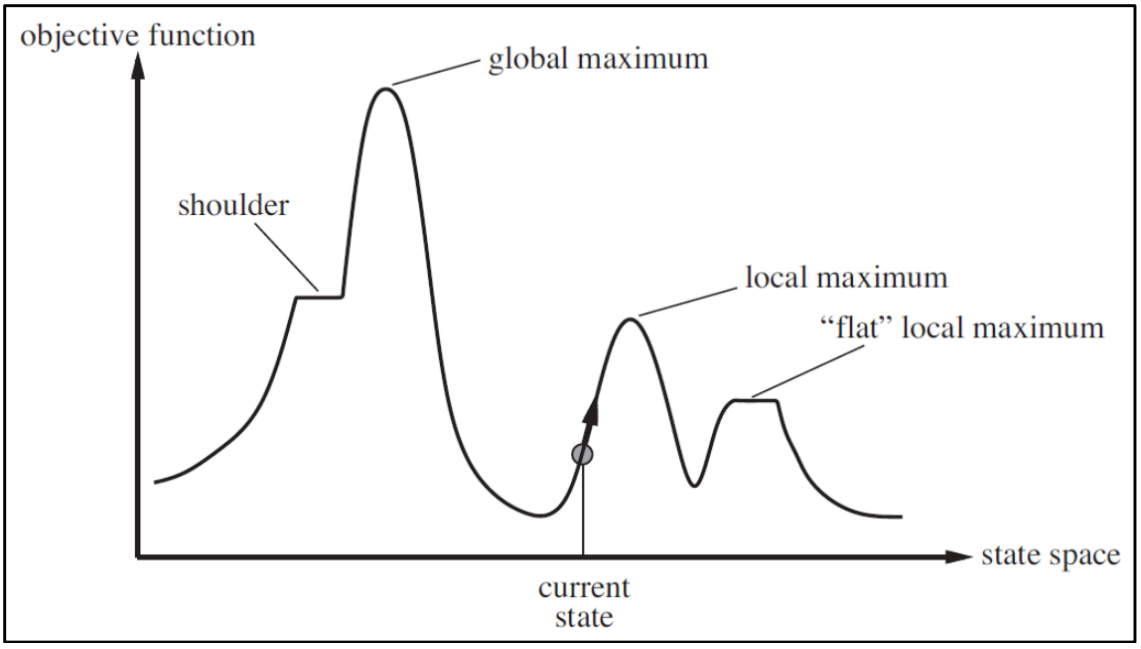

- 爬山法的缺点：容易陷入局部最优解。
    1. 局部最大值：局部极大值是一个比它的每个邻居状态都高的峰顶，但是比全局最大值要低。爬山法找不到最优解。
    2. 山脊：就是一系列的局部最大值，爬山法搜索容易陷入死循环。
    3. 高原：高原是在状态空间地形图上评价函数值平坦的一块区域。像上图的`shoulder`（山肩）和`flat local maximum`（水平的局部最大值）都是高原。爬山法搜索效率降低。
- 解决优点：从不同的状态开始运行爬山法看看哪个解更好。

爬山法和模拟退火的区别

因为爬山法是局部贪婪算法，所以容易陷入局部最优解；模拟退火算法是全局优化算法，它可以接受比当前更差的解，所以不会容易陷入局部最优解，并且随着时间慢慢降低接受差解的概率。

模拟退火

三函数两准则(状态生成函数 状态接受函数 降温函数 退火结束准则 内循环终止准则)

流程图：

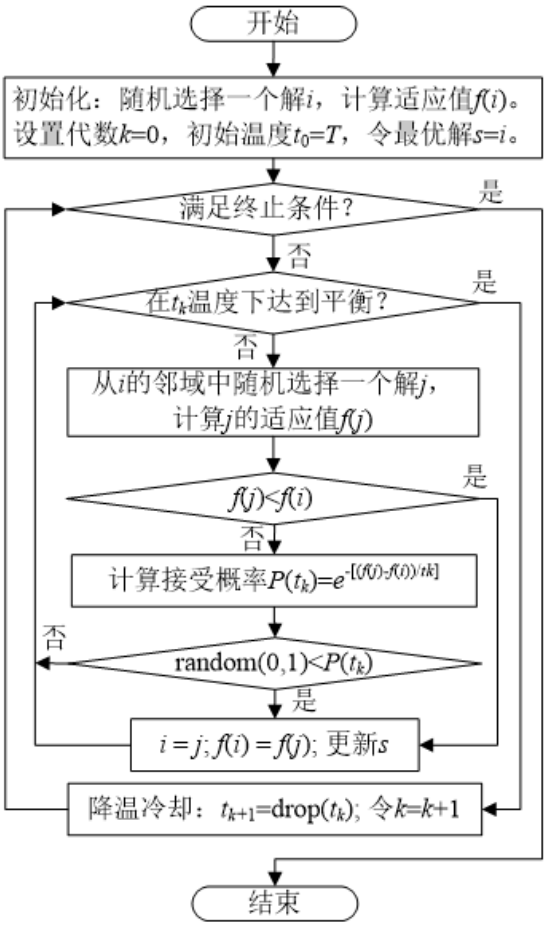


```
//功能：模拟退火算法伪代码
//说明：本例以求问题最小值为目标
//参数：T为初始温度; L为内层循环次数

procedure SA
  //Initialization
    Randomly generate a solution X0, and calculate its
    fitness value f(X0);
  Xbest=X0; k=0; tk=T;
  while not stop
    //The search loop under the temperature tk
    for i=1 to L  //The loop times
      Generate a new solution Xnew based on the current
      solution Xk, and calculate its fitness value f(Xnew).
      if f(Xnew) < f(Xk)
          Xk = Xnew;
          if f(Xk) < f(Xbest) Xbest=Xk;
          continues;
      end if
      Calculate P(tk)=e^-[(f(Xnew)-f(Xk))/tk];
       if random(0,1) < P
          Xk = Xnew;
      end if
    end for
    //Drop down the temperature
    tk+1=drop(tk); k=k+1;
  end while
  print Xbest
end procedure
```

已知：
物体个数：n=5
背包容量：c=8
重量 w = (2, 3, 5, 1, 4)
价值 v = (2, 5, 8, 3, 6)

第一步：初始化。假设初始解为i=(11001)，初始温度为T=10。计算$f(i)$=2+5+6=13，最优解s=i

第三步：降温，假设温度降为T=9。如果没有达到结束标准，则返回第二步继续执行

假设在继续运行的时候，从当前解i=(10110)得到一个新解j=(00111)，这时候的函数值为$f(j)$=8+3+6=17，这是一个全局最优解。可见上面过程中接受了劣解是有好处的。

第二步：在T温度下局部搜索，直到“平衡”，　假设平衡条件为执行了3次内层循环。
（2-1）产生当前解i的一个邻域解j（如何构造邻域根据具体的问题而定，这里假设为随机改变某一位的0/1值或者交换某两位的0/1值），假设j=(11100)
要注意产生的新解的合法性，要舍弃那些总重量超过背包装载量的非法解

（2-2）$f(j)$ = 2+5+8=15 > 13=$f(i)$，所以接受新解j
i=j; $f(i)$=$f(j)$=15; 而且s=i;
要注意求解的是最大值，因此适应值越大越优

（2-3）返回（2-1）继续执行。
(a) 假设第二轮得到的新解j=(11010)，由于$f(j)$ = 2+5+3=10 < 15=$f(i)$，所以需要计算接受概率$P(T)$=exp(($f(j)$-$f(i)$)/T) = exp(-0.5) = 0.607，假设random(0,1)>$P(T)$，则不接受新解

(b) 假设第三轮得到的新解j=(10110)，由于$f(j)$ = 2+8+3=13 < 15=$f(i)$，所以需要计算接受概率$P(T)$=exp(($f(j)$-$f(i)$)/T) = exp(-0.3) = 0.741，假设random(0,1)<$P(T)$，则接受新解
按照一定的概率接受劣解，也是跳出局部最优的一种手段

（2-4）这时候，T温度下的“平衡”已达到（即已经完成了3次的邻域产生），结束内层循环

遗传算法（基本操作）

遗传算法的一般步骤为

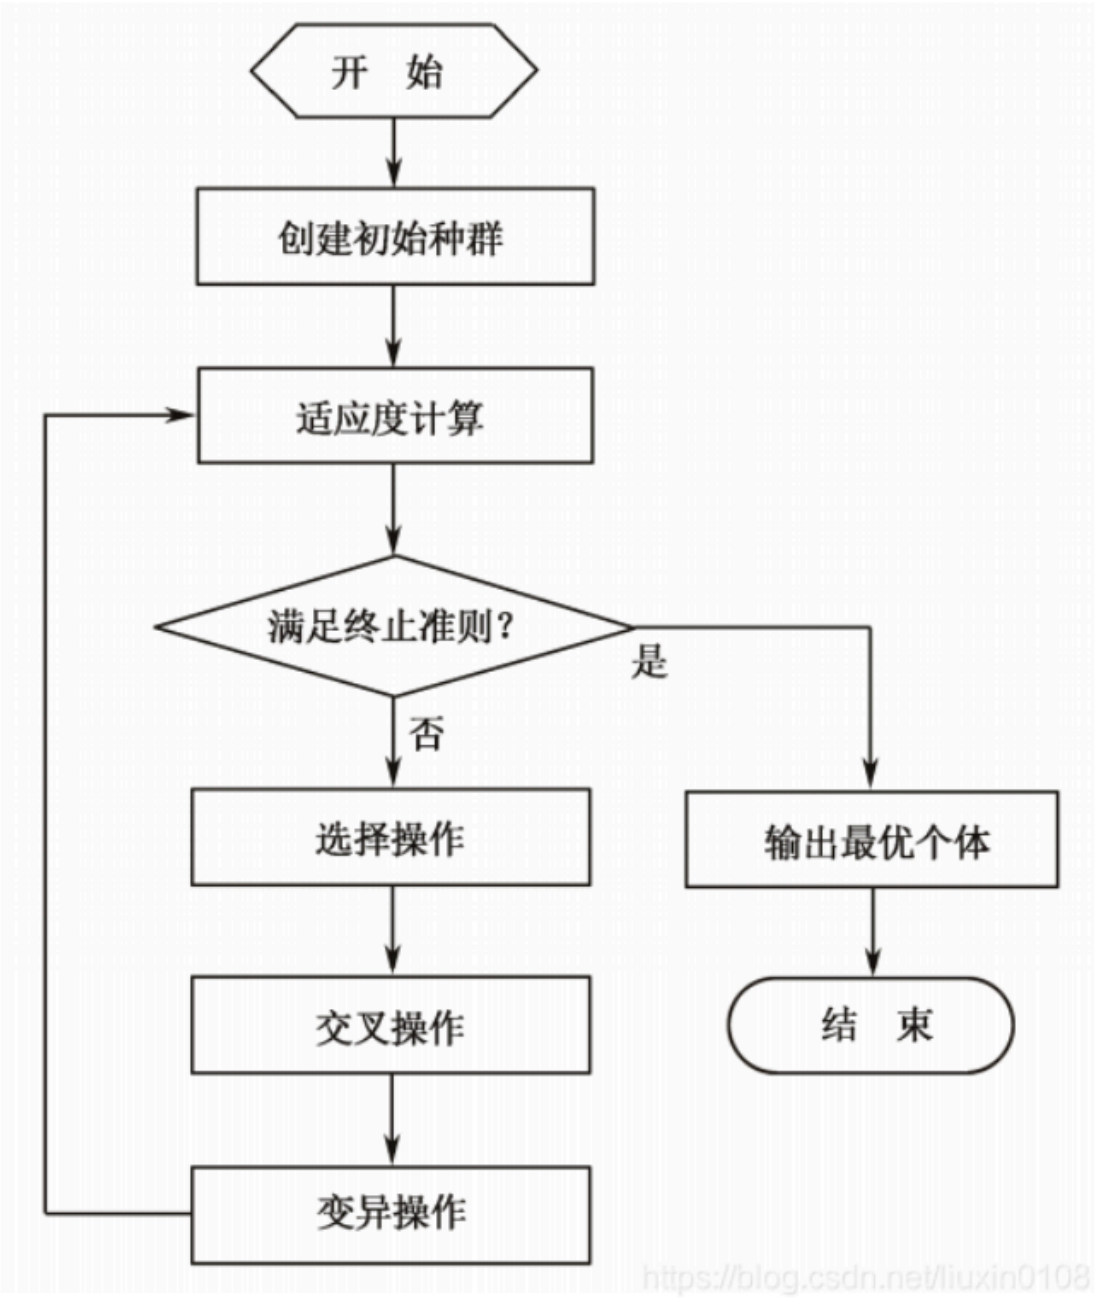

流程中，不一定每个个体都会发生**交叉**和**变异**，都是有概率的。

包括编码、适应度函数、**选择**、**交叉**、**变异**。(后面三种为基本操作)

- 编码：就是将每个个体进行二进制编码。
- 适应度函数：返回值是判断该个体的适应度，适应度越大代表该个体越好。
- 选择：选择是用来确定重组或交叉个体，以及被选个体将产生多少个子代个体。适应度越大的个体被选择的概率越大。选择方法有：

1. 轮盘赌：首先按照适应度比例分配给每个个体被选中的概率，然后所有个体被选中概率之和为1，再随机[0,1]生成浮点数，看落在哪个区间，就选择哪个个体。

个体	1	2	3	4	5	6	7	8	9	10	11
适应度	2.0	1.8	1.6	1.4	1.2	1.0	0.8	0.6	0.4	0.2	0.1
选择概率	0.18	0.16	0.15	0.13	0.11	0.09	0.07	0.06	0.03	0.02	0.0
累积概率	0.18	0.34	0.49	0.62	0.73	0.82	0.89	0.95	0.98	1.00	1.00

第1轮产生一个随机数：0.81　　第2轮产生一个随机数：0.32

2. 锦标赛选择：就是按照轮盘赌抽几个个体进行适应度比较，适应度高的个体被选择，一直重复执行下去。

- 交叉：结合父代中选择的个体中的信息而产生新的个体。交叉方法有：
  1. 单点交叉：在个体串中随机设定一个交叉点，实行交叉时，该点前或后的两个个体的部分结构进行互换，并生成两个新的个体。

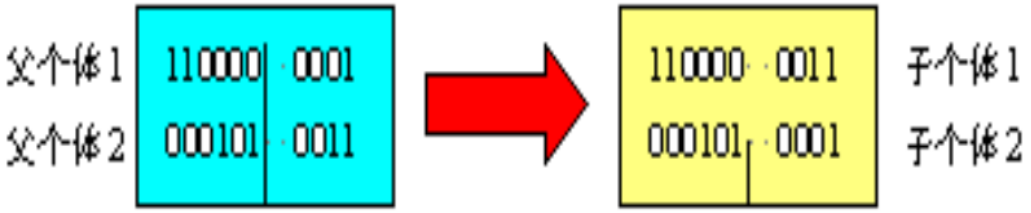

  2. 两点交叉：随机设置两个交叉点，将两个交叉点之间的码串相互交换。
- 变异：子代基因按小概率扰动产生的变化。变异方法有：
  1. 位点变异：群体中的个体码串，随机挑选一个或多个基因座，并 对这些基因座的基因值以变异概率作变动。

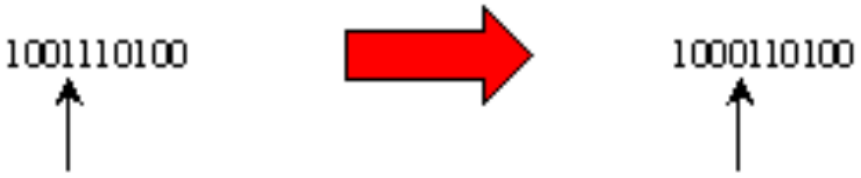

- 遗传算法的特点：遗传搜索是针对**一组候选解决方案**（individuals）而不是单个候选方案进行的。在搜索过程中，算法会保留当前一代的一组个体。遗传算法的每次迭代都会创建下一代个体。相反，大多数其他搜索算法都维持单个解决方案，并迭代地修改它以寻找最佳解决方案。例如，梯度下降算法沿当前最陡下降方向迭代移动当前解，梯度方向为给定函数的梯度的负数。
- 遗传算法的群体初始化规模：太小会导致局部最优解，太大会难以收敛。
- 例子：TSP旅行商问题、背包问题

第五章 不确定知识表示以及推理

考点

1. 贝叶斯网络定义及表示、联合概率表示、构建方法、朴素贝叶斯方法、独立性判断D分离；
2. 贝叶斯网络边缘概率及条件概率计算。

贝叶斯网络定义及表示

- 定义：它由一个有向无环图（表达了变量之间的有向依赖关系）和一系列条件概率表（衡量了上述关系的强度）组成。

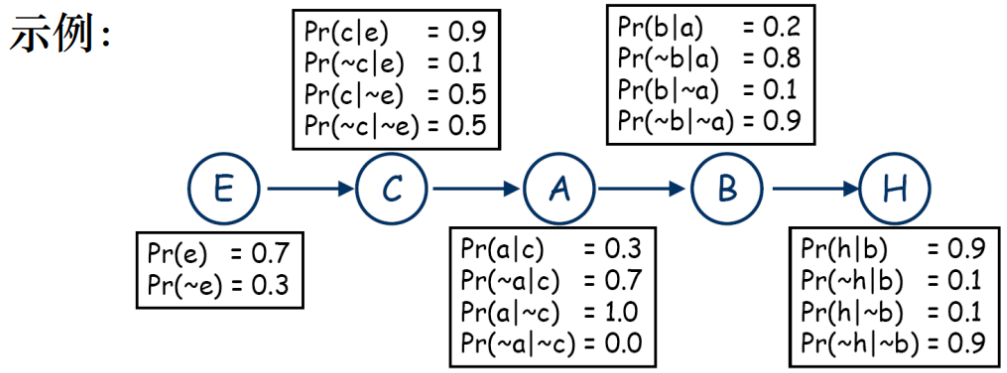

$$Pr(H,B,A,C,E) = Pr(H|B,A,C,E)Pr(B|A,C,E)Pr(A|C,E)Pr(C|E)P(E) \quad 31个参数$$
$$Pr(H,B,A,C,E) = Pr(H|B)Pr(B|A)Pr(A|C)Pr(C|E)P(E) \quad 9个参数$$

- 补充：P(e)可推出P(~e)（一个参数），需要知道P(c|e)和P(c|~e)可推出P(~c|e)和P(~c|~e)（两个参数）。以此类推。
- 贝叶斯网络的构建：
  1. 在某种变量顺序下，对所有变量的联合概率应用链式 法则 Pr(X1,...,Xn) = Pr(Xn|X1,..., Xn-1)Pr(Xn-1|X1,..., Xn-2)...Pr(X1)
  2. 对于每个变量Xi ，考虑该变量的条件集合X1,...,Xi-1，Xi 和Xj 是条件独立的，则将Xj 从Xi 的 条件集合中删除。经过这一步骤，可以得到下式 Pr(X1,...,Xn) = Pr(Xn|Par(Xn))Pr(Xn-1|Par(Xn-1))...Pr(X1)。
  3. 基于上述公式，构建一个有向无环图。其中，对于每个用节点表示的变量Xi，其父节点为Par(Xi)中的变量集合。
  4. 为每个家庭（即变量及其父节点集合）确定条件概率表的取值。

朴素贝叶斯方法（上网找些题目看看）

- 定义：就是人为定义条件独立的变量，使得式子变得更加简单。即类似**P(A,B,C,D) = P(A|B)P(C|B)P(D|B)**。

后验概率$Pr(B = \text{yes} \mid A <= 30, I = \text{medium}, S = \text{yes}, C = \text{fair}) = ?$

先验概率$Pr(B = \text{yes}) = 9/14 \approx 0.64$

似然度$Pr(A <= 30, I = \text{medium}, S = \text{yes}, C = \text{fair} \mid B = \text{yes}) = Pr(A <= 30 \mid B = \text{yes}) * Pr(I = \text{medium} \mid B = \text{yes}) * Pr(S = \text{yes} \mid B = \text{yes}) * Pr(C = \text{fair} \mid B = \text{yes}) = (2/9) * (4/9) * (6/9) * (6/9)$

归一化后，$Pr(B = \text{yes} \mid A <= 30, I = \text{medium}, S = \text{yes}, C = \text{fair}) = 0.8$ 买电脑的置信度上升！

- 就是先算给定x向量情况下y为正的可能性和y为负的可能性。

轻松搞定朴素贝叶斯(有例题) 朴素贝叶斯算法例题-CSDN博客这个讲的挺好的。

条件概率

- 极大似然法：就是先把式子列出来，然后对数，再对该式子求导并且等于0。
  - 极大似然法：
  - 示例2：
    - 某超市销售的糖果有2种口味（*cherry*和*lime*），包装纸的颜色分为绿色和红色
    - 糖果的口味决定了包装纸的颜色
    - 假设尝到c颗*cherry*口味的（其中g_c颗为绿色包装纸，r_c颗为红色包装纸），以及l颗*lime*口味的（其中g_l颗为绿色包装纸，r_l颗为红色包装纸）

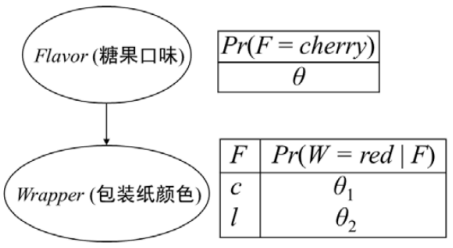

$$Pr(d \mid h_{\theta,\theta_1,\theta_2}) = \theta^c \theta_1^{r_c} (1-\theta_1)^{g_c} (1-\theta)^l \theta_2^{r_l} (1-\theta_2)^{g_l}$$

$$c/\theta - l/(1-\theta) = 0 \Rightarrow \theta = c/(c+l)$$

$$r_c/\theta_1 - g_c/(1-\theta_1) = 0 \Rightarrow \theta_1 = r_c/(r_c+g_c)$$

$$r_l/\theta_2 - g_l/(1-\theta_2) = 0 \Rightarrow \theta_2 = r_l/(r_l+g_l)$$

贝叶斯网络的D-分离

- 串形连接： 在串行连接中A通过事件B影响C，同样事件C也是用过事件B影响A。我们认为当**证据B确定时**，A、C条件独立。

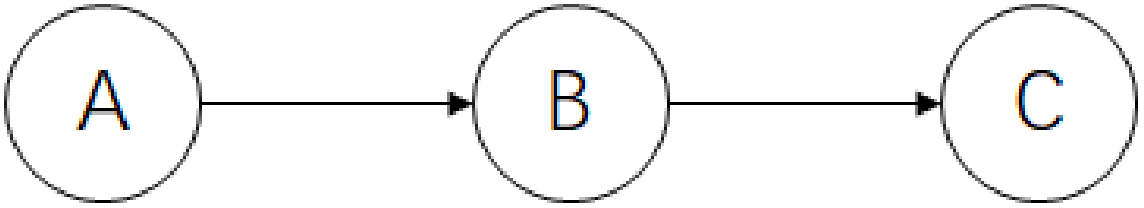

- 共同的原因：**给定父节点的前提下**，子节点们条件独立。

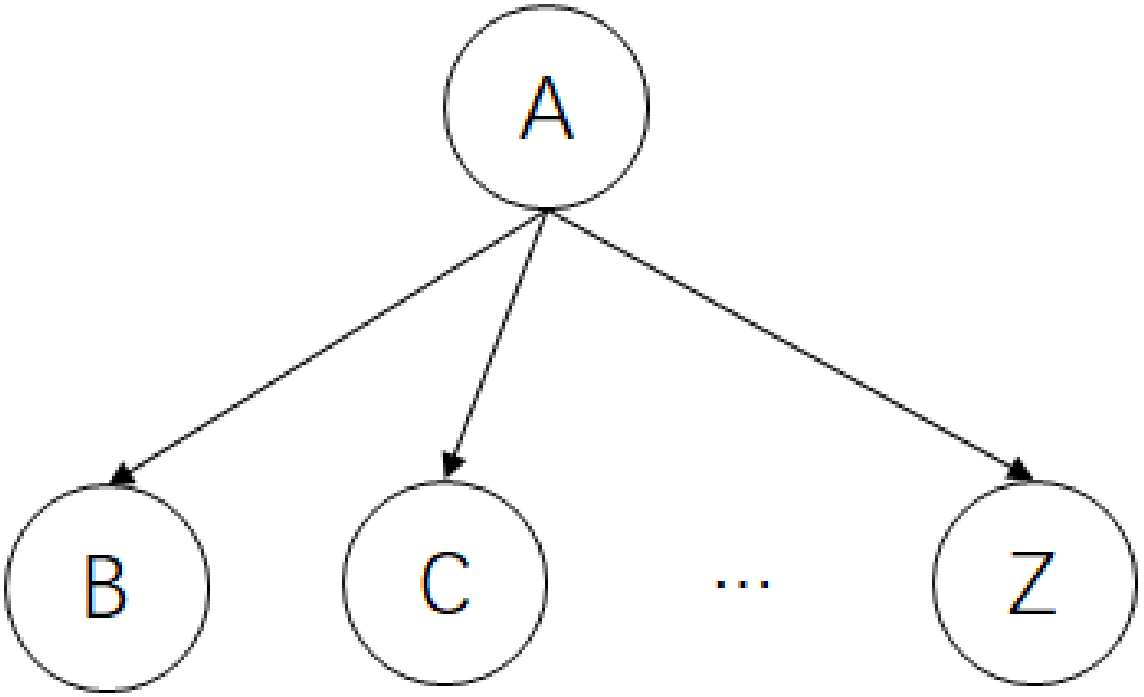

- 共同的作用：**当不给定子节点时**，父节点们条件独立。

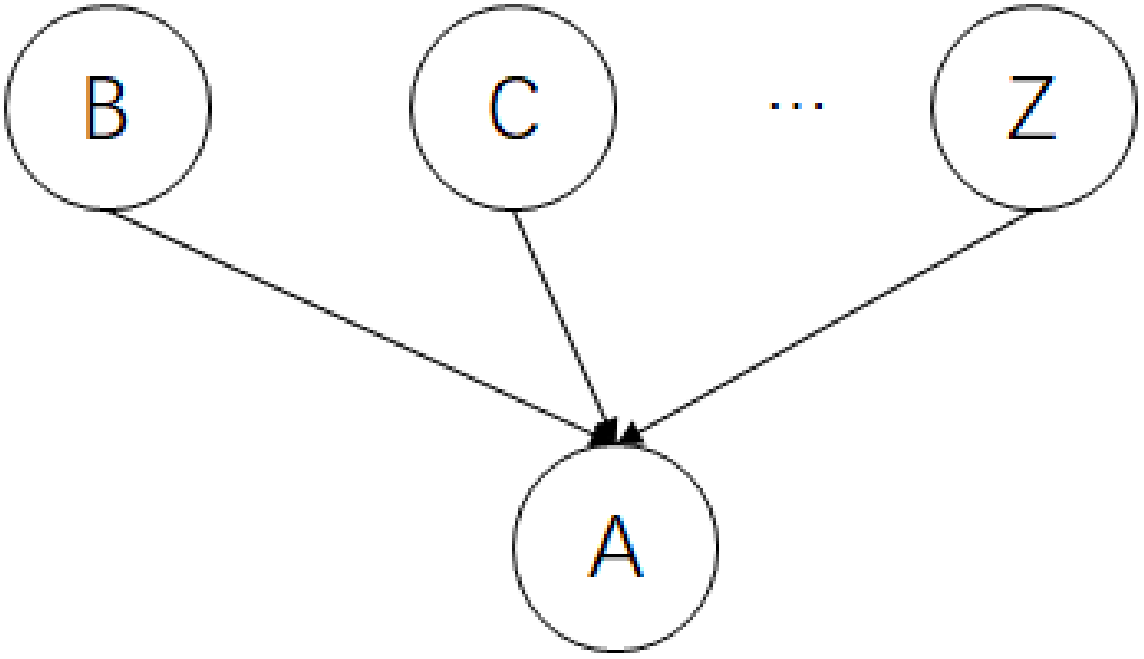

- 若存在一条路径将这两个节点（直接）连通，则称这两个节点是**相关**的。若不存在这样的路径将这两个节 点连通，则这两个节点就是**独立**的。

贝叶斯网络计算

- 就是一直使用加法原理把父节点加入到式子中，然后链式法则，再对式子展开（条件独立就可以删除）。

$$P(m \mid a,b) = \frac{P(m,a,b)}{P(a,b)} = \frac{P(m,a,b,e) + P(m,a,b,\sim e)}{P(a,b,e) + P(a,b,\sim e)}$$
$$= \frac{P(b)P(e)P(a \mid b,e)P(m \mid a) + P(b)P(\sim e)P(a \mid b,\sim e)P(m \mid a)}{P(b)P(e)P(a \mid b,e) + P(b)P(\sim e)P(a \mid b,\sim e)} = P(m \mid a)$$

第七章 机器学习

考点

1. 监督学习（分类与回归，感知机、逻辑回归；神经网络、**反向传播**、CNN、RNN）；
2. 非监督学习（Kmeans）；
3. 强化学习（MDP定义、状态值函数和动作值函数、Q学习及SARSA、DQN）。

有监督学习

- 定义：会给定**输入特征**和输出的**标签**（Y）

分类

- 定义：预测**离散**型变量。给定(x1, y1), (x2, y2), ..., (xn, yn)，学习一个输入x、预测y的函数f(x)。y是**离散**的。

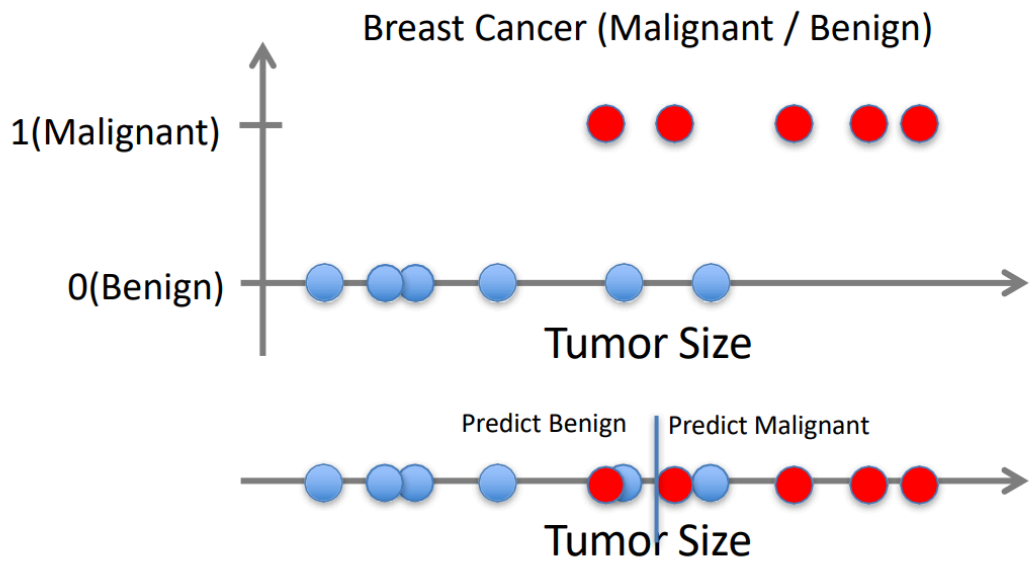

回归

- 定义：预测**连续**性变量。给定(x1, y1), (x2, y2), ..., (xn, yn)，学习 一个输入x、预测y的函数f(x) 。y是**连续**的。

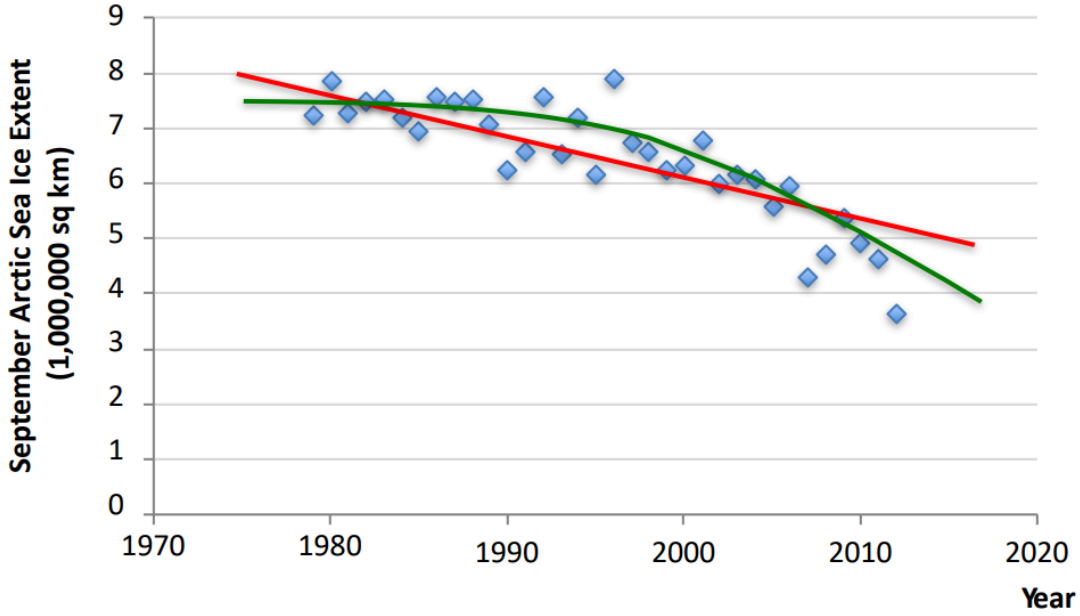

联结主义（Connetionism）学派：认为人工智能源于**仿生学**。（神经网络）

感知机学习

解决**二分类问题**的算法。是有监督学习中的**分类**。

- 定义：主要是处理**线性可分**的数据。对于拥有d个特征的 x=(x1,x2,...,xd) , 计算它的带权"分数" 。如果分数大于0则预测为真，分数小于0则预测为假。
- 输入层：感知机接收一组输入特征向量 x=(x1,x2,...,xn)，每个输入有一个对应的权重 w=(w1,w2,...,wm)。
- 加权求和：输入特征向量和权重向量进行加权求和，计算公式为：

$$z = \mathbf{w} \cdot \mathbf{x} + b = \sum_{i=1}^{n} w_i x_i + b$$

其中，b是偏置。

- 激活函数：加权求和的结果通过激活函数（通常是阶跃函数）进行处理，输出一个二值结果。阶跃函数的定义为：

$$f(z) = \begin{cases} 1 & \text{if } z \geq 0 \\ 0 & \text{if } z < 0 \end{cases}$$

- 损失函数：定义为所有误分类点到分类线距离的总和。（M是所有误分类点的集合）

$$L(w, b) = -\sum_{\mathbf{x}_i \in M} y_i (w \cdot \mathbf{x}_i + b)$$

修改函数利用梯度下降法：

$$\nabla_w L(w, b) = -\sum_{\mathbf{x}_i \in M} y_i \mathbf{x}_i$$
$$\nabla_b L(w, b) = -\sum_{\mathbf{x}_i \in M} y_i$$

- 感知机学习：
  1. 先初始化权重向量w(0)和偏置b，然后根据D来修正w和b。（通常初始化为0）
  2. 对于每个训练样本，计算感知机的输出。
  3. 如果感知机某个样本的输出与真实标签不一致，根据以下规则更新权重和偏置：

$$w_{i+1} \leftarrow w_i + \eta y_i x_i$$
$$b \leftarrow b + \eta y_i$$

     其中η是学习率。

  4. 跳回第二步。

- 分类图片如下：

- 遍历数据的顺序不同，可能会导致结果不同，因此有多个解存在。

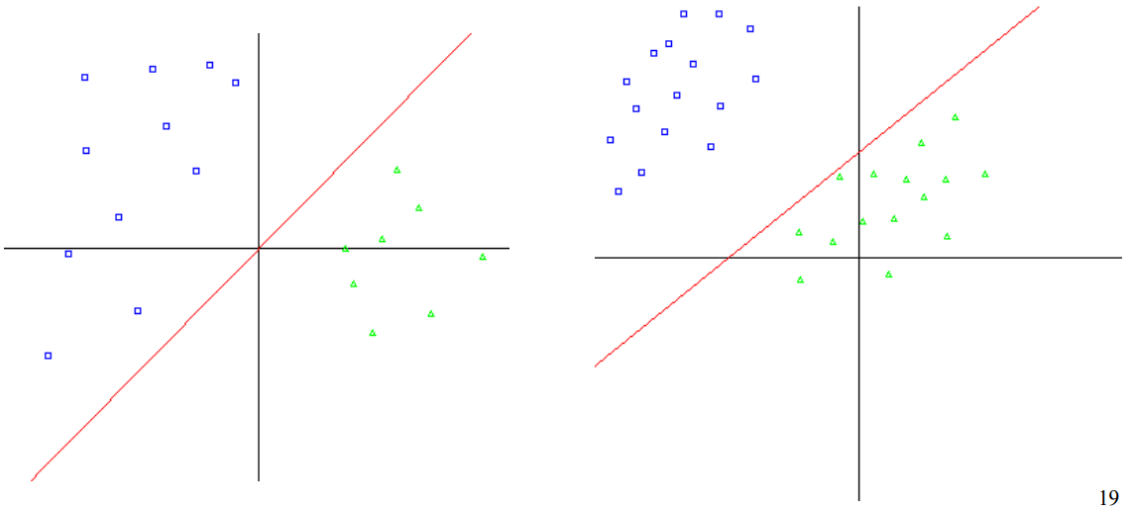

19

逻辑回归

感知机算法只要计算的分数大于0输出标签为真，可是分数**1**和**1000**也是输出标签为真。

解决**多分类**的算法。

- 定义：和**感知机学习算法**一样，主要处理线性可分的数据。对于拥有d个特征的 x=(x1,x2,...,xd) , 计算一个0到1的概率值，表示**样本属于某个类别的概率。**
- 输入层：感知机接收一组输入特征向量 x=(x1,x2,...,xn)，每个输入有一个对应的权重 w=(w1,w2,...,wm)。gai
- 加权求和：输入特征向量和权重向量进行加权求和，计算公式为：

$$y = \mathbf{w} \cdot \mathbf{x} + b = \sum_{i=1}^{n} w_i x_i + b$$

  其中，输出y是该样本属于这个类别的可能性（目前还未经过转化），b是偏置。

- 激活函数：使用Logistic函数将求和y映射到一个介于 0 和 1 之间的概率值：

$$\sigma(y) = \frac{1}{1 + e^{-y}}$$

  这里的σ(y)是把刚刚加权求和的总数转换成概率。若y越大，则概率σ(y)就越大。

- 损失函数：定义为交叉熵函数。

$$L(w) = -\sum_{i=1}^{N} [y_i \log(q_i) + (1 - y_i) \log(1 - q_i)]$$

  yi 是第 i 个样本的真实标签（0或1），qi是模型预测的第 i 个样本属于类别 1 的概率。当qi越接近yi，损失函数值就越小。（等价于让损失函数最小）

  修改函数利用梯度下降法：

$$\nabla_{\mathbf{w}} L(\mathbf{w}) = -\sum_{i=1}^{N} [y_i - q_i] \mathbf{x}_i$$

- 逻辑回归学习：
  1. 初始化w和偏置 b，通常可以选择为零或者随机初始化。
  2. 对于每个训练样本 (xi,yi)，计算模型的预测输出 qi=σ(w·xi+b)。
  3. 如果某个样本的输出与真实标签不一致，根据以下规则更新权重和偏置：

$$\mathbf{w} \leftarrow \mathbf{w} - \eta \sum_{i=1}^{N} [q_i - y_i] \mathbf{x}_i$$

  4. 跳回第二步。
- 其实本质是二分类输出还是0和1，还是一条直线。

人工神经网络

单层神经网络

- 定义：一个基本的神经网络包括：**输入**、**计算**、**输出**。下图是一个典型的人工神经网络模型，它包含3个输入，1个 输出，以及2个计算功能。

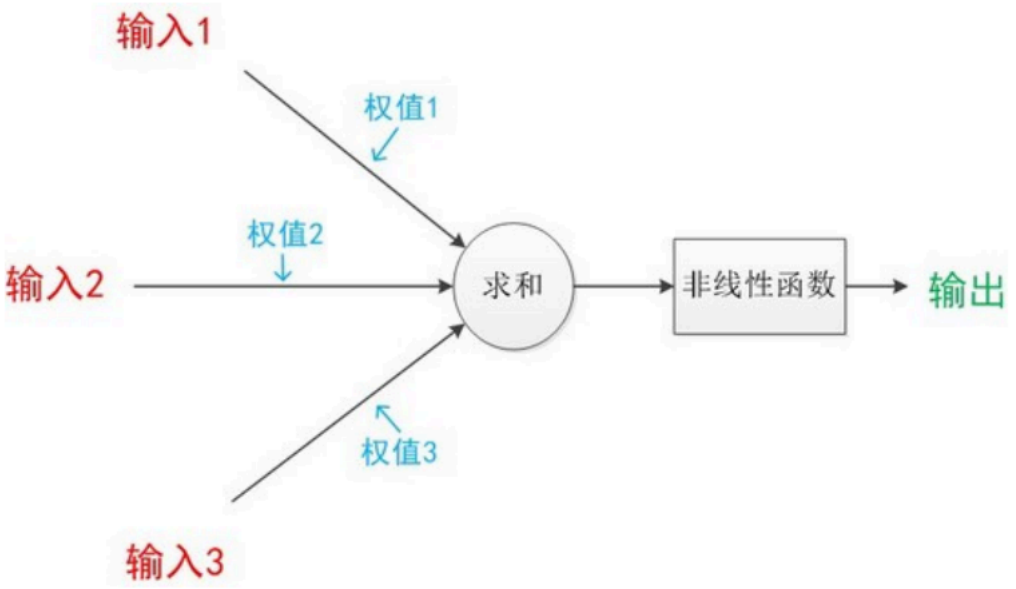

- 人工神经元：人工神经网络中的计算单位。由下列部分组成：
    1. 输入信号xi
    2. 一个激活层对输入信号乘上加权求和，神经元的激活层由加权输入的总和确定。
    3. 一个阈值函数 f(x)，该函数通过确定激活是低于还是高于阈值来计算最终输出。
- 应用：可以实现“与”、“或”功能，可是不能处理异或。

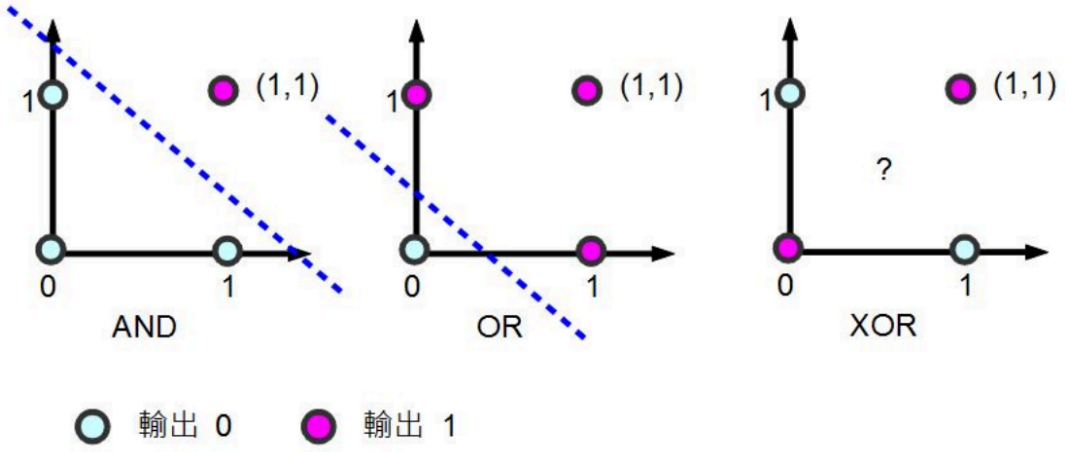

多层神经网络

优势：单层神经网络只能处理线性问题，而两层神经网络可以无限逼近**任意连续函数。**面对复杂的非线性分类任务，带一个隐藏层的两层神经网络可以分类的很好。输入和输出节点之间的附加层称为**隐藏层。**

原因：从输入层到隐藏层时， 数据发生了**空间变换。**这是因为输入层的阈值函数是**非线性**的，对数据进行了转换。

传递：训练的算法每次迭代都有**前向传递阶段**和**反向传递阶段。**

1. 前向传递阶段：利用第(l)层处的神经元的输出来计算第(l+1)层的输出。
2. 反向传递阶段：第(l+1)层的权重在更新第(l)层的权重之前被更新。

激活函数：

1. 双曲正切函数(tanh)：

$$\tanh(x) = \frac{e^x - e^{-x}}{e^x + e^{-x}}$$
$$\tanh'(x) = 1 - \tanh^2(x)$$

2. sigmoid函数：

$$f(x) = \frac{1}{1 + e^{-x}}$$
$$f'(x) = f(x)\,(1 - f(x))$$

函数的**导数**特性很重要！

损失函数：定义为最小二乘法：

$$E = \frac{1}{2}e^2 = \frac{1}{2}(T - O)^2$$

为了使用梯度下降调整权重 wjk,我们首先计算在wjk 上误差E的偏导数：

$$\begin{aligned}\frac{\partial E}{\partial w_{jk}} &= \frac{\partial E}{\partial e} \times \frac{\partial e}{\partial O_k} \times \frac{\partial O_k}{\partial w_{jk}} \\ &= -(e) \times (O_k(1 - O_k)) \times (O_j) \\ &= -(T_k - O_k)O_k(1 - O_k)O_j\end{aligned}$$

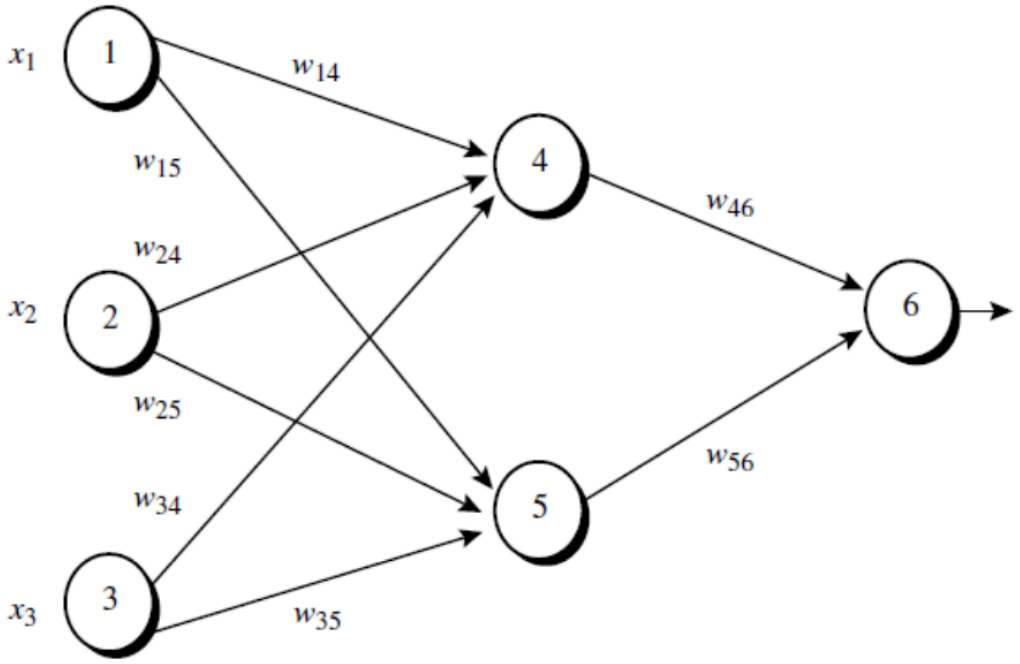

前向传播输入：

- 净输入：$I_j = \sum_i w_{ij} O_i + \theta_j$
- 净输出：$O_j = \frac{1}{1 + e^{-I_j}}$

反向传播误差：

- 对于**输出层**，定义误差为：$Err_k = O_k(1-O_k)(T_k-O_k)$
- 对于**隐藏层**，定义误差为：

$$Err_j = O_j(1-O_j)\sum_k Err_k w_{jk}$$

- **权重更新公式**（利用梯度下降）：

$$w_{jk} = w_{jk} + \eta Err_k O_j$$

$$\theta_k = \theta_k + \eta Err_k$$

- 缺点：很容易梯度消失，每传递一层梯度就是原本的0.25倍。
- (´▽`) 欢迎回来！ (cnblogs.com)把这题刷一下基本没问题了(更改偏置b1和b2的时候，这个偏置项有点特殊，可以看成是一个隐藏层的节点进行处理，o1和o2的Err值都对它影响)

卷积神经网络(CNN)

- 是**深度学习**算法。主要用于图像识别。
- 卷积计算：如下图

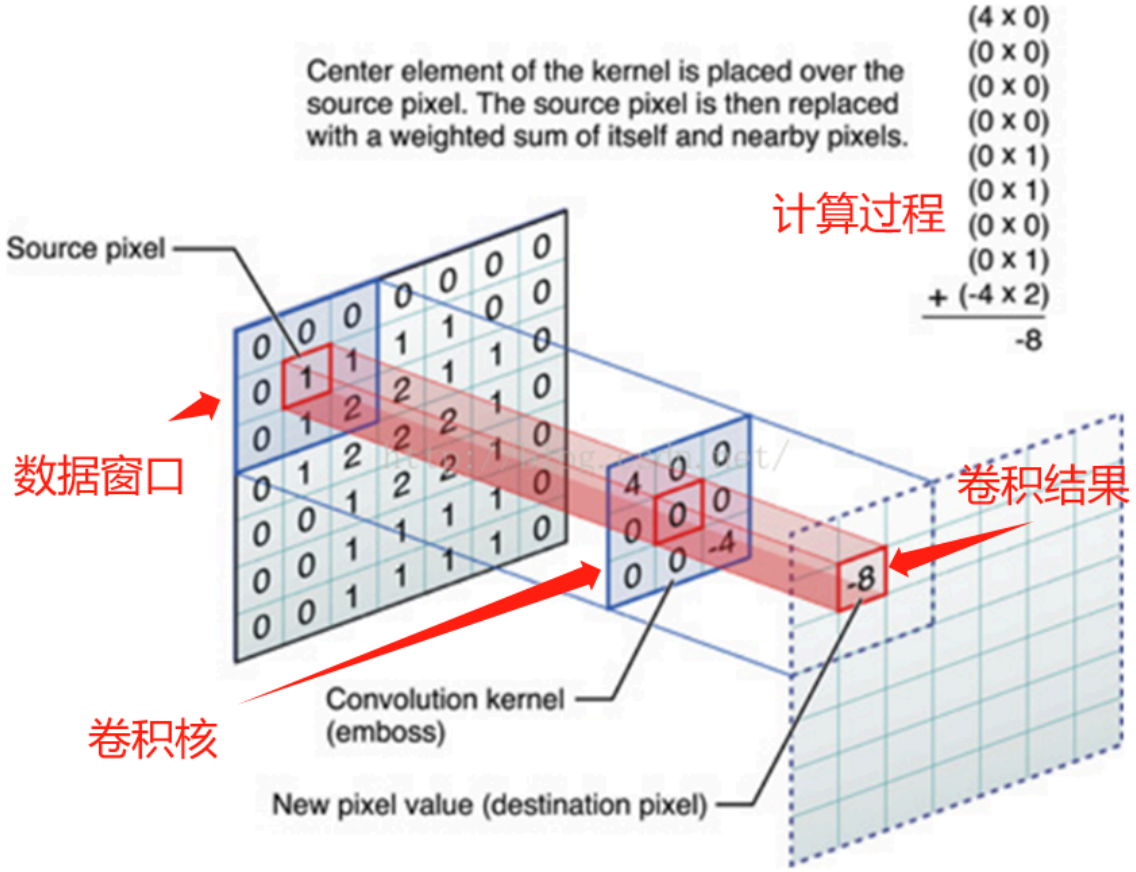

描述卷积的四个量：卷积核个数、**卷积核大小f**、**填充0值p**、**步长s。**

假设原本大小为拿，卷积结果大小为(n可以是高或者宽)

$$\frac{n+2p-f}{s}+1$$

- 卷积神经网络的构造
    1. 输入层：输入层接收原始图像数据。图像通常由三个颜色通道（红、绿、蓝）组成。（输入数据）
    2. 卷积层（可以有**多层卷积层**）：将输入图像与卷积核进行卷积，然后再进行**非线性变换**(RELU)，再进行**池化。**（提取特征）RELU函数为：

$$\mathrm{ReLU}(x) = \max(0, x)$$

    3. 全连接层：全连接层将提取的特征映射转化为网络的最终输出。（就是多层神经网络）

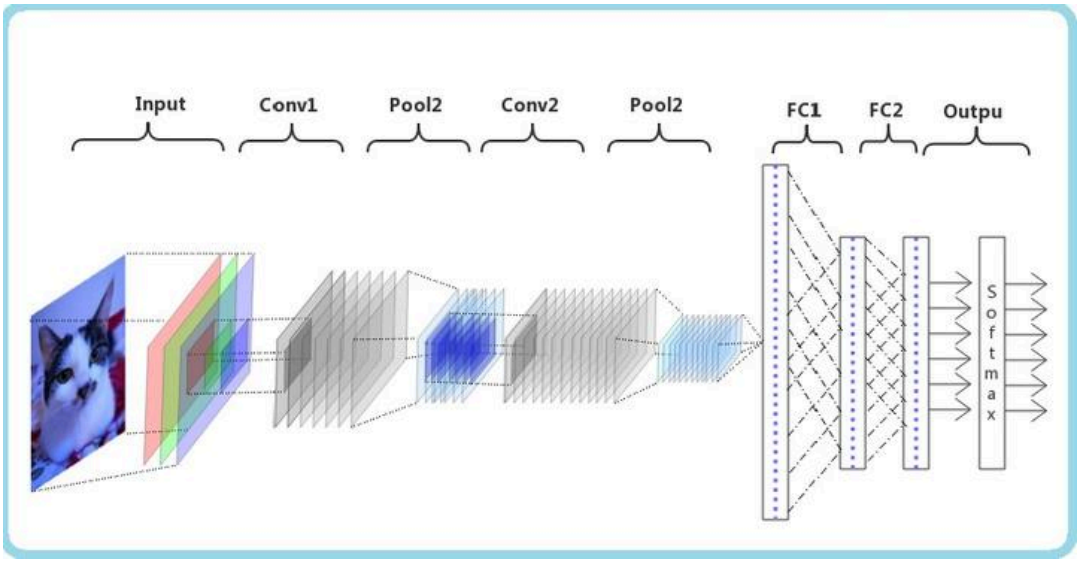

    4. 输出层：输出层是CNN的最后一层，其神经元的数量**等于分类任务中的类别数。**输出层的激活函数根据任务的不同而选择，例如Softmax用于多分类任务，Sigmoid用于二分类任务。
- 卷积神经网络（CNN）是一种深度学习方法，它的发展历史可以追溯到20世纪90年代。最早的CNN是由Yann LeCun等人提出的，他们利用多层感知机（MLP）进行手写数字识别。随着技术的进步，CNN的结构变得越来越复杂，性能也得到了显著提高。
- 输入层用于接收原始数据，通常是图像数据。图像通常由三个颜色通道（红、绿、蓝）组成，每个通道包含图像的像素值。输入层只是数据的初始存储区域，不进行任何处理。
- 卷积层是CNN的核心部分，主要用于提取输入数据的局部特征。卷积层通过在每个位置计算卷积核与输入数据的点积，卷积操作后，特征图通过激活函数进行非线性变换，这种非线性变换使模型能够学习和表示更复杂的特征。池化层用于对卷积层生成的特征图进行下采样，减少特征图的尺寸，从而降低计算复杂度。
- 全连接层位于网络的最后几层，将前面层提取到的特征整合并映射到最终的输出。全连接层类似于传统的多层神经网络，每个神经元与上一层的所有神经元相连。通过全连接层，模型能够基于提取到的特征进行分类或回归任务。
- **卷积神经网络和全连接神经网络区别**：卷积神经网络有**卷积层**能够提取更多的数据特征，并且卷积的时候参数是**共享**的还有**平移不变**性。

循环神经网络（RNN）

- 是**深度学习**算法，主要用于语言识别。

- 因为其余的神经网络输出只和当前时刻网络的输入相关。可是像预测天气这种问题还是很需要**之前**的数据的。这是一个**有记忆**的神经网络。

- 例如像判断广州是目的地还是出发地，需要看前一个英文单词，所以需要用到之前的记忆。

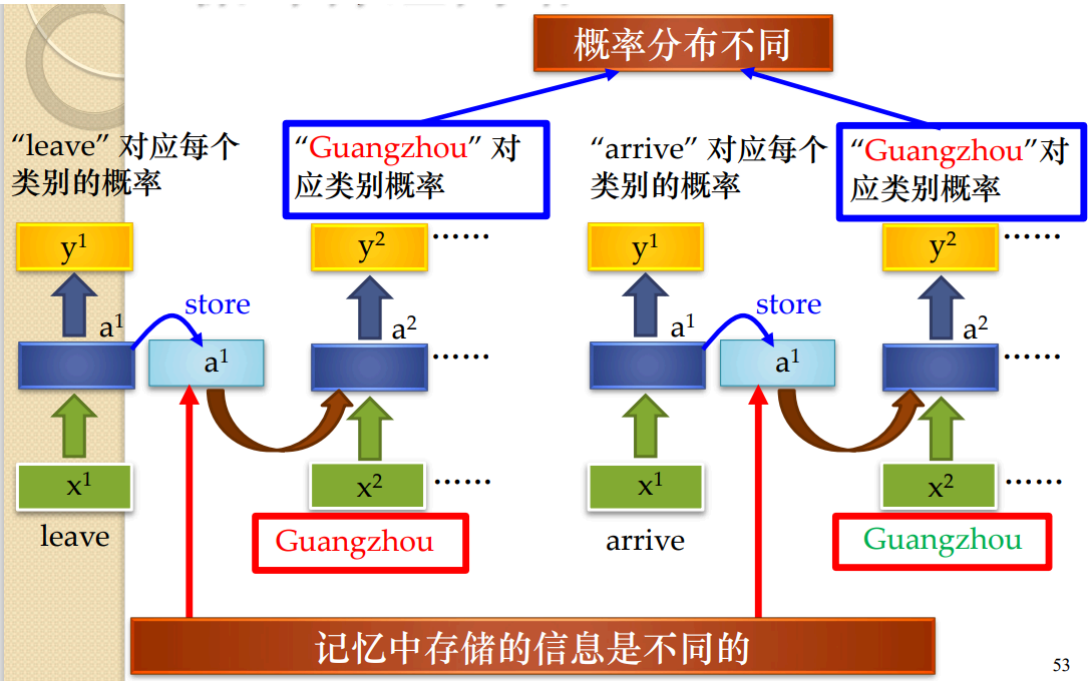

- 简单来说，就是隐藏层的输出还存储在记忆中，并且记忆内容作为隐藏层的输入。

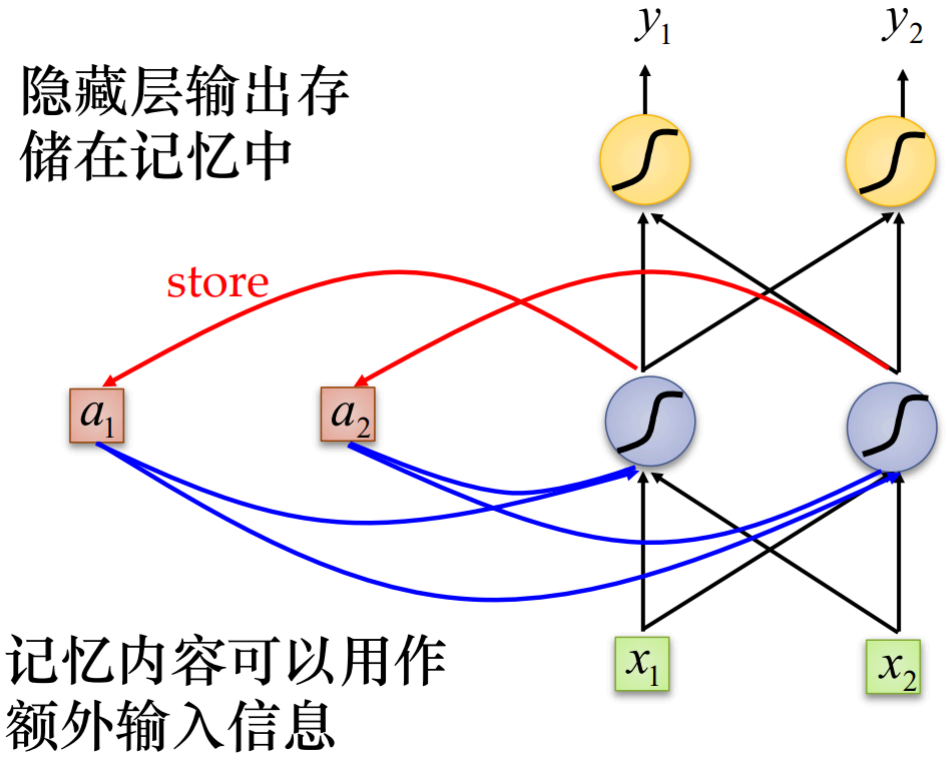

- 例子如下：假设所有权重都是1，激活函数都是线性的。

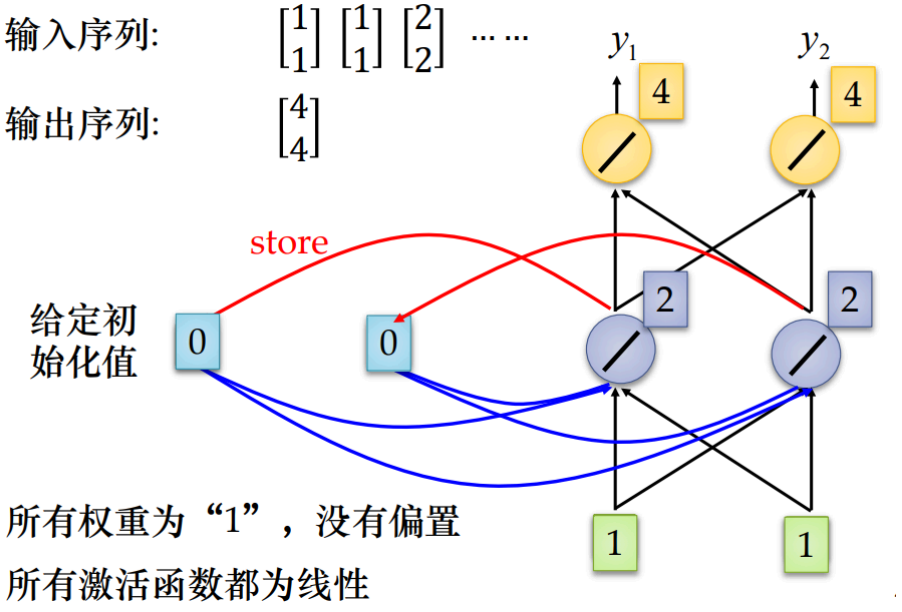

- 第一步：

- 第二步：

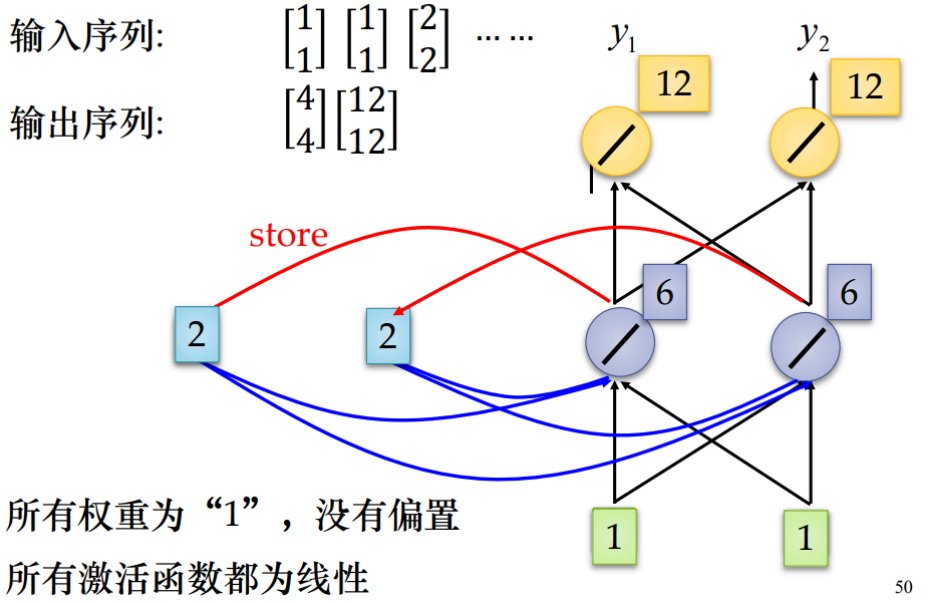

- 第三步：

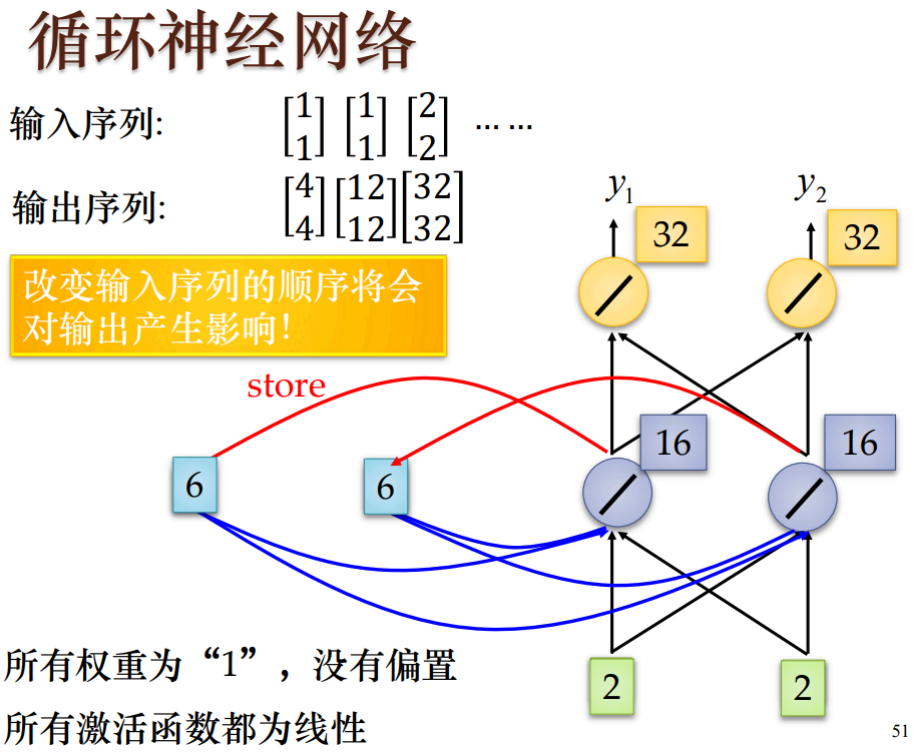

- **不同的**输入顺序会影响到循环神经网络的输出，因为是**有记忆**的！

基本上理解卷积神经网络就是眼睛，主要用来图像识别；循环神经网络就像嘴巴，主要用来语言识别。

无监督学习

就是不会给出**标签**的学习。

K-Means

- **聚类**：基于距离度量，将对象集合**聚类到簇(cluster)中**，使得簇内对象的距离**尽量小**，且簇之间对象的距离**尽量大**。
- 向量x和y之间距离公式：
    1. **街区距离**：

$$d(x,y)=\sum_{i=1}^{n}|x_i-y_i|$$

n是向量的维度。

2. **欧式距离**：

$$d(x,y)=\sqrt{\sum_{i=1}^{n}(x_i-y_i)^2}$$

n是向量的维度。

- K-Means算法流程：
  1. **初始化**：
     - 确定聚类的数目K。
     - 随机选择K个数据点当作质心。
  2. **分配每个点到最近的质心**：
     - 对于每个数据点，计算它到每个质心的距离。
     - 将每个数据点分配到距离最近的质心所属的簇。
  3. **更新质心**：
     - 对于每个簇，计算所有属于该簇的数据点的平均值，这个平均值就是新的质心。
     - 更新质心的位置为新的平均值。
  4. **重复步骤2和步骤3**：
     - 反复执行步骤2和步骤3，直到质心不再发生变化，或者达到预设的迭代次数。
  5. **完成聚类**：
     - 最终的质心和数据点的分配结果即为K-means算法的输出。
- K-Means算法改进：

  可以发现，一开始选择的质心很重要，很影响算法。所以初始化的质心应该离得越远越好。
  - K-Means++算法：
    1. 计算每个数据点x到最近的一个已选质心的距离

       对于每个数据点 x，计算它到最近的一个已选质心的距离D(x)。假设我们已经选择了m 个质心 c1,c2,...,cm。

$$D(x)=\min_{i\in\{1,2,...,m\}}\text{dist}(x,c_i)$$

    2. 计算每个点被选中当质心的概率

       将每个数据点 x 到最近质心的距离 D(x) 的平方作为该点被选为下一个质心的概率权重。具体来说，计算概率权重：

$$P(x)=\frac{D(x)^2}{\sum_{y\in X}D(y)^2}$$

    3. 轮盘赌选择下一个质心

       离被选中的质心越远被选做质心的可能性越大。

强化学习

强化学习基本要素有：**状态**、**动作**、**策略**、**奖励**、值函数（**状态值函数**、**动作值函数**）

强化学习的基本目标是：**找到最大化奖励的策略。**

- 状态值函数V(s)：用于评断当前状态s在给定策略π下，未来累计的期望值。

$$V^{\pi}(s) = \mathbb{E}_{\pi}\left[\sum_{t=0}^{\infty}\gamma^{t}R_{t+1} \mid S_0 = s\right]$$

$$V(s) = \underbrace{R(s)}_{\text{Immediate reward}} + \underbrace{\gamma \sum_{s' \in S} P(s'|s)V(s')}_{\text{Discounted sum of future rewards}}$$

  两条公式是**等价**的。

- 动作值函数Q(s,a)：表示在状态 s 下采取动作 a，然后遵循策略 π 时，未来累积奖励的期望值。

Q-learning

是一种**贪心**算法，学习的策略和实际的策略可能**不同。异策略。**

通过反复的试验和更新，逐渐逼近最优的状态值函数（Q函数），从而找到最优策略。

更新Q值的公式如下：

$$Q(s,a) \leftarrow r + \gamma \max_{a'} Q(s',a')$$

其中r是到达s'的奖励。

更新Q值时，因为是贪心算法，所以取s'状态的**max值。**

SARSA

学习的策略与实际执行的策略是**一致**的。**同策略。**

更新Q值的公式如下：

$$Q(s,a) \leftarrow r + \gamma Q(s',a')$$

更新Q值时，所以取s'状态的Q值。

Q-learning 和 SARSA区别

1. 策略类型
   - Q-learning: Off-policy，学习的策略（最优策略）与执行的策略（探索策略）不同。
   - SARSA: On-policy，学习的策略与执行的策略相同。
2. 更新Q值的依据
   - Q-learning: 更新Q值时使用的是新状态s'下的最大Q值（maxQ(s',a')）。
   - SARSA: 更新Q值时使用的是新状态s'下实际选择的动作的Q值（Q(s',a')）。

TD时序差分

更改Q值的时候，还会利用到原本的Q值。

- 可以与**Q-learning**和**SARSA**混合使用。
- **Q-learning TD**算法公式：

$$Q(s,a) \leftarrow (1-\alpha)Q(s,a) + \alpha\left[r + \gamma \max_{a'} Q(s',a')\right]$$

- **SARSA TD**算法公式：

$$Q(s,a) \leftarrow (1-\alpha)Q(s,a) + \alpha\left[r + \gamma Q(s',a')\right]$$

  α是学习率，γ是折扣因子。

DQN

是**Q-learning算法**和**深度神经网络**结合，并额外引入两个机制**经验回放**和**目标网络。**

- 经验回放：将智能体探索环境得到的数据储存起来，然后随机采样小批次样本更新深度神经网络的参数。
- 目标网络：额外引入一个目标网络（和Q网络具有同样的网络结构），此目标网络不更新梯度，每隔一段时间将Q网络的参数赋值给此目标网络。
- 实现步骤：
  1. **初始化神经网络**：包括主网络和目标网络的初始化。
  2. **与环境交互**：使用当前策略（通常是 ε-greedy 策略）与环境交互，收集经验数据。
  3. **存储经验**：将每次交互的经验（状态、动作、奖励、下一个状态）存储到经验回放缓冲区中。
  4. **经验回放**：从经验回放缓冲区中随机抽取小批量的经验样本，用于训练主网络。
  5. **Q-learning 更新**：使用抽样的经验样本，计算 Q-learning 的目标并更新主网络的参数。
  6. **更新目标网络**：定期更新目标网络的参数，以保持其与主网络的一致性，但更新频率较低，如每隔一定步数更新一次。
  7. **迭代训练**：重复上述步骤直至收敛或达到预定的训练步数。
- DQN和深度神经网络区别
  1. 概括
     - 深度神经网络是一种通用的机器学习模型，用于学习输入数据中的复杂模式和特征。
     - DQN 是一种强化学习算法，结合了深度神经网络和Q-learning的思想。
  2. 训练方法
     - 深度神经网络训练通常使用监督学习或无监督学习的方法，通过最小化预测输出与真实标签之间的损失来优化网络参数。
     - DQN训练过程是通过交互式学习与环境进行，智能体通过试错和反馈来优化动作值函数。

押题

谓词归结一题 **贝叶斯网络一题 A*一题 Minimax剪枝一题** 感觉爬山法可能会有一题

遗传一题

Qlearning一题

k-means一题

BP一题